

# Devoir Maison 1

---

## 1 Théorie

### 1.1 Estimation par moindres carrées du vecteur $\vec{\beta}$

#### Exercice 1

On a que  $\forall \vec{u} \in \mathbb{R}^d$  :

$$J_n(\vec{u}) := \|\vec{Y} - Z\vec{u}\|^2$$

Soit  $\hat{u} \in \operatorname{argmin}_{\vec{u} \in \mathbb{R}^p} J_n(\vec{u})$ . Nous avons que  $\hat{u}$  est solution de :

$$\nabla_{\vec{u}} J_n(\vec{u}) = -2Z^t(\vec{Y} - Z\vec{u}) = 0$$

Cela est égale à zéro si et seulement si :

$$Z^t \vec{Y} = Z^t Z \vec{u} \tag{1}$$

Donc  $\hat{u}$  est solution de l'équation 1.

□

#### Exercice 2

Nous avons que :

$$Z^\# = (Z^t Z)^{-1} Z^t$$

Montrons d'abord l'identité :

$$Z^\# Z = (Z^t Z)^{-1} Z^t Z = (Z^t Z)^{-1} (Z^t Z) = I_p$$

Regardons maintenant :

$$H := Z Z^\# = Z (Z^t Z)^{-1} Z^t$$

$$H^2 = Z (Z^t Z)^{-1} Z^t Z (Z^t Z)^{-1} Z^t$$

$$H^2 = Z (Z^t Z)^{-1} (Z^t Z) (Z^t Z)^{-1} Z^t$$

$$H^2 = Z (Z^t Z)^{-1} Z^t = H$$

## Devoir Maison 1

---

Donc  $H$  est une projection.

Soit  $\vec{u} \in \mathbb{R}^n$  un vecteur. Nous avons que:

$$H\vec{u} = Z(Z^t Z)^{-1} Z^t \vec{u} = Z \underbrace{[(Z^t Z)^{-1} Z^t \vec{u}]}_{\phi \in \mathbb{R}^p}$$

C'est à dire,  $H\vec{u} \in \text{Vect}(\vec{Z}^1, \dots, \vec{Z}^p)$ . Donc  $H$  est le projecteur orthogonal sur l'espace vectoriel engendrée par les colonnes de la matrice  $Z$ .

□

### Exercice 3

L'estimateur de moindres carrées  $\hat{\beta}$  est tel que :

$$\hat{\beta} \in \operatorname{argmin}_{\vec{\beta} \in \mathbb{R}^p} J_n(\vec{\beta})$$

Comme montré dans l'exercice 1, cela est équivalent à :

$$Z^t Y = Z^t Z \hat{\beta}$$

Or, comme  $Z^t Z$  est une matrice carrée de dimension  $p \times p$  inversible, nous avons un système d'équations avec une solution unique pour  $\hat{\beta}$ .

Donc :

$$\hat{\beta} = (Z^t Z)^{-1} Z^t Y = Z^\# Y$$

□

### Exercice 4

Nous utilisons le fait que les erreurs de régression sont homoscedastiques, donc que  $\forall \theta \in \Theta$  :

$$\mathbb{E}_\theta[\varepsilon(\theta)] = 0$$

Nous avons que :

$$Y = Z\vec{\beta} + \sigma\varepsilon(\theta)$$

Donc :

$$\mathbb{E}_\theta[Y] = \mathbb{E}_\theta[Z\vec{\beta}] + \sigma\mathbb{E}_\theta[\varepsilon(\theta)] = \mathbb{E}_\theta[Z\vec{\beta}]$$

## Devoir Maison 1

---

En utilisant le fait que l'espérance est linéaire et le résultat obtenu dans l'exercice 3 ( $\hat{\beta} = Z^\# Y$ ) :

$$Z^\# \mathbb{E}_\theta[\vec{Y}] = \mathbb{E}_\theta[Z^\# \vec{Y}] = \mathbb{E}_\theta[\hat{\beta}]$$

Donc, en remplaçant dans l'expression et en utilisant la linéarité de l'espérance :

$$\mathbb{E}_\theta[\hat{\beta}] = Z^\# \mathbb{E}_\theta[\vec{Y}] = Z^\# \mathbb{E}_\theta[Z \vec{\beta}] = \mathbb{E}_\theta[Z^\# Z \vec{\beta}] = \mathbb{E}_\theta[\vec{\beta}] = \vec{\beta}$$

Donc  $\hat{\beta}$  est un estimateur sans biais.

□

### Exercice 5

Comme  $\hat{\beta} = Z^\# Y$ , nous avons que :

$$\text{Var}_\theta(\hat{\beta}) = Z^\# (\text{Var}_\theta Y) Z^{\#t}$$

On remarque que :

$$Y = Z \vec{\beta} + \sigma \vec{\varepsilon}(\theta)$$

Comme  $\text{Var}_\theta(\vec{\beta}) = 0$ , en utilisant que  $\text{Var}_\theta(\vec{\varepsilon}(\theta)) = \text{I}_n$  :

$$\text{Var}_\theta(Y) = \sigma^2 \text{Var}_\theta(\vec{\varepsilon}(\theta)) = \sigma^2 \text{I}_n$$

Donc :

$$\text{Var}_\theta(\hat{\beta}) = \sigma^2 Z^\# Z^{\#t}$$

On remarque aussi que :

$$Z^\# Z^{\#t} = (Z^t Z)^{-1} Z^t Z ((Z^t Z)^{-1})^t = ((Z^t Z)^{-1})^t$$

Comme  $Z^t Z$  est symétrique, nous avons que :

$$Z^\# Z^{\#t} = (Z^t Z)^{-1}$$

Donc :

$$\text{Var}_\theta(\hat{\beta}) = \sigma^2 (Z^t Z)^{-1}$$

□

# Devoir Maison 1

---

## Exercice 6

Démontrons par double implication.



Supposons que  $\tilde{\beta}$  est sans biais.

Nous avons que :

$$Y = Z\vec{\beta} + \sigma\vec{\varepsilon}(\theta)$$

Donc :

$$\mathbb{E}_\theta[\vec{\varepsilon}] = 0 \implies \mathbb{E}_\theta[Y] = \mathbb{E}_\theta(Z\vec{\beta}) = Z\vec{\beta}$$

On multiplie par  $B$  des deux cotés :

$$\mathbb{E}_\theta(BY) = BZ\vec{\beta}$$

$$\mathbb{E}_\theta(\tilde{\beta}) = BZ\vec{\beta}$$

Comme  $\tilde{\beta}$  est sans biais :

$$\vec{\beta} = BZ\vec{\beta}$$

Donc  $BZ = I_p$ .



On suppose que  $BZ = I_p$ , donc :

$$BZ\vec{\beta} = \vec{\beta} \implies B\mathbb{E}_\theta[Z\vec{\beta}] = \vec{\beta}$$

Vu que  $\mathbb{E}_\theta[\varepsilon] = 0$ ,  $\mathbb{E}_\theta[Z\vec{\beta}] = \mathbb{E}[Y]$ , donc :

$$B\mathbb{E}_\theta[Z\vec{\beta}] = \vec{\beta} \implies \mathbb{E}_\theta[BY] = \vec{\beta} \implies \mathbb{E}_\theta[\tilde{\beta}] = \vec{\beta}$$

Et donc  $\tilde{\beta}$  est sans biais, ce qui finit la preuve par double implication.

□

## Exercice 7

Nous avons que :

## Devoir Maison 1

---

$$\mathbb{E}_\theta[\varepsilon] = 0 \implies \mathbb{E}_\theta[Y] = Z\vec{\beta}$$

Développons l'expression :

$$\mathbb{E}_\theta[(\tilde{\beta} - \vec{\beta})(\hat{\beta} - \vec{\beta})^t] = \mathbb{E}_\theta[\tilde{\beta}\hat{\beta}^t - \tilde{\beta}\vec{\beta}^t - \vec{\beta}\hat{\beta}^t + \vec{\beta}\vec{\beta}^t]$$

On utilise le fait que  $\hat{\beta} = Z^\#Y$  et  $\tilde{\beta} = BY$  :

$$\mathbb{E}_\theta[(\tilde{\beta} - \vec{\beta})(\hat{\beta} - \vec{\beta})^t] = \mathbb{E}_\theta[BY Y^t Z^{\#t} - BY \vec{\beta}^t - \vec{\beta} Y^t Z^{\#t}] + \vec{\beta} \vec{\beta}^t$$

$$\mathbb{E}_\theta[(\tilde{\beta} - \vec{\beta})(\hat{\beta} - \vec{\beta})^t] = B\mathbb{E}_\theta[YY^t]Z^{\#t} - B\mathbb{E}_\theta[Y]\vec{\beta}^t - \vec{\beta}\mathbb{E}_\theta[Y^t]Z^{\#t} + \vec{\beta}\vec{\beta}^t \quad (2)$$

On utilise à nouveau que  $\mathbb{E}_\theta[\varepsilon] = 0$ , ce qui implique que  $\mathbb{E}_\theta[Y] = Z\vec{\beta}$  :

$$\sigma^2 \varepsilon \varepsilon^t = (Y - Z\vec{\beta})(Y^t - \vec{\beta}^t Z^t) = YY^t - Y\vec{\beta}^t Z^t - Z\vec{\beta} Y^t + Z\vec{\beta} \vec{\beta}^t Z^t$$

Comme  $\text{Var}_\theta(\varepsilon) = \mathbb{E}_\theta[\varepsilon \varepsilon^t] = \text{I}_n$ , nous avons que :

$$\sigma^2 \mathbb{E}_\theta[\varepsilon \varepsilon^t] = \sigma^2 \text{I}_n = \mathbb{E}_\theta[YY^t] - \mathbb{E}_\theta[Y]\vec{\beta}^t Z^t - Z\vec{\beta} \mathbb{E}_\theta[Y^t] + Z\vec{\beta} \vec{\beta}^t Z^t$$

Vu que  $\mathbb{E}_\theta[Y] = Z\vec{\beta}$ , nous avons que :

$$\sigma^2 \mathbb{E}_\theta[\varepsilon \varepsilon^t] = \sigma^2 \text{I}_n = \mathbb{E}_\theta[YY^t] - Z\vec{\beta} \vec{\beta}^t Z^t - Z\vec{\beta} \vec{\beta}^t Z^t + Z\vec{\beta} \vec{\beta}^t Z^t$$

Donc :

$$\mathbb{E}_\theta[YY^t] = Z\vec{\beta} \vec{\beta}^t Z^t + \sigma^2 \text{I}_n \quad (3)$$

On utilise 2 et 3 avec le fait que  $\mathbb{E}_\theta[Y] = Z\vec{\beta}$  :

$$\mathbb{E}_\theta[(\tilde{\beta} - \vec{\beta})(\hat{\beta} - \vec{\beta})^t] = BZ\vec{\beta} \vec{\beta}^t Z^t Z^{\#t} + B\sigma^2 \text{I}_n Z^{\#t} - BZ\vec{\beta} \vec{\beta}^t - \vec{\beta} \vec{\beta}^t Z^t Z^{\#t} + \vec{\beta} \vec{\beta}^t$$

Or, on rappelle que  $BZ = \text{I}_n$  :

$$\mathbb{E}_\theta[(\tilde{\beta} - \vec{\beta})(\hat{\beta} - \vec{\beta})^t] = \vec{\beta} \vec{\beta}^t Z^t Z^{\#t} + \sigma^2 BZ^{\#t} - \vec{\beta} \vec{\beta}^t - \vec{\beta} \vec{\beta}^t Z^t Z^{\#t} + \vec{\beta} \vec{\beta}^t$$

$$\mathbb{E}_\theta[(\tilde{\beta} - \vec{\beta})(\hat{\beta} - \vec{\beta})^t] = \sigma^2 BZ^{\#t}$$

$$\mathbb{E}_\theta[(\tilde{\beta} - \vec{\beta})(\hat{\beta} - \vec{\beta})^t] = \sigma^2 BZ((Z^t Z)^{-1})^t$$

## Devoir Maison 1

---

$$\mathbb{E}_\theta[(\tilde{\beta} - \vec{\beta})(\hat{\beta} - \vec{\beta})^t] = \sigma^2((Z^t Z)^{-1})^t$$

Comme  $Z^t Z$  est une matrice symétrique,  $((Z^t Z)^{-1})^t = (Z^t Z)^{-1}$ , donc :

$$\boxed{\mathbb{E}_\theta[(\tilde{\beta} - \vec{\beta})(\hat{\beta} - \vec{\beta})^t] = \sigma^2(Z^t Z)^{-1}}$$

□

### Exercice 8

On remarque que comme  $\tilde{\beta} = BY$  et  $\text{Var}_\theta[Y] = \sigma^2 I_n$  :

$$\text{Var}_\theta(\tilde{\beta}) = \sigma^2 B B^t = \text{Cov}_\theta(\tilde{\beta}, \tilde{\beta})$$

Nous avons aussi que :

$$\hat{\beta} = Z^\# Y \implies \text{Cov}_\theta(\hat{\beta}, \hat{\beta}) = \text{Var}_\theta \hat{\beta} = \sigma^2 Z^\# Z^{\#t} = \sigma^2 (Z^t Z)^{-1} = \text{Cov}_\theta(\tilde{\beta}, \hat{\beta})$$

Nous avons donc que :

$$\text{Var}_\theta(\tilde{\beta} - \hat{\beta}) = \text{Cov}_\theta(\tilde{\beta} - \hat{\beta}, \tilde{\beta} - \hat{\beta}) = \text{Var}_\theta(\tilde{\beta}) + \text{Var}_\theta(\hat{\beta}) - 2\text{Cov}_\theta(\tilde{\beta}, \hat{\beta})$$

On utilise que

$$\text{Cov}_\theta(\tilde{\beta}, \hat{\beta}) = \text{Var}_\theta(\hat{\beta})$$

Donc, comme la matrice de covariance est positive semi-définie :

$$\text{Var}_\theta(\tilde{\beta} - \hat{\beta}) = \text{Var}_\theta(\tilde{\beta}) - \text{Var}_\theta(\hat{\beta}) \geq 0$$

Donc  $\forall x \in \mathbb{R}^p$  :

$$x^t (\text{Var}_\theta(\tilde{\beta}) - \text{Var}_\theta(\hat{\beta})) x \geq 0 \implies \text{Var}_\theta \tilde{\beta} \succcurlyeq \text{Var}_\theta \hat{\beta}$$

□

## 1.2 Estimation de la variance $\sigma^2$ et Coefficient de détermination

### Exercice 9

Nous avons que :

## Devoir Maison 1

---

$$\mathbb{E}_\theta[\hat{\sigma}^2] = \frac{1}{n-p} \mathbb{E}_\theta[\text{tr}((Y - Z\hat{\beta})(Y - Z\hat{\beta})^t)] = \frac{1}{n-p} \text{tr}(\text{Var}(Y - Z\hat{\beta}))$$

On remarque que :

$$\text{Var}((I_p - H)Y) = \sigma^2(I_p - H)I(I_p - H)^t$$

$$\text{Var}((I_p - H)Y) = \sigma^2(I_p - H)(I_p - H)^t$$

$$\text{Var}((I_p - H)Y) = \sigma^2(I_p - H - H + H)$$

$$\text{Var}((I_p - H)Y) = \sigma^2(I_p - H)$$

On remplace dans l'équation précédente :

$$\mathbb{E}_\theta[\hat{\sigma}^2] = \frac{1}{n-p} \text{tr}(\sigma^2 I_p - \sigma^2 H) = \frac{\sigma^2}{n-p} (\text{tr} I_p - \text{tr} H)$$

Or, nous avons que  $\text{tr} I_n = n$ . Aussi, comme  $H$  est une matrice  $p \times p$  projection orthonormal nous avons que  $\text{tr} H = n$ .

Nous avons donc que :

$$\mathbb{E}_\theta[\hat{\sigma}^2] = \sigma^2$$

### Exercice 10

Comme  $H$  est projection orthogonal  $Y = HY + (I_p - H)Y$ , cela implique que :

$$\|Y\|^2 = \|HY\|^2 + \|(I - H)Y\|^2$$

Or, comme  $\text{SSE} = \|HY\|^2$  et  $\text{RSS} = \|(I_p - H)Y\|^2$  :

$$\|Y\|^2 = \text{SSE} + \text{RSS}$$

## 1.3 Cas de la régression linéaire gaussienne

### Exercice 11

Nous avons que  $Y \sim \mathcal{N}(Z\vec{\beta}, \sigma^2 I_n)$

## Devoir Maison 1

---

Écrivons maintenant la log-vraisemblance :

$$p_\theta(Y) = \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\frac{\|Y - Z\vec{\beta}\|^2}{2\sigma^2}}$$

$$\ln(\vec{\beta}, \sigma^2) = -\frac{n}{2} \log 2\pi\sigma^2 - \frac{1}{2\sigma^2} \|Y - Z\vec{\beta}\|^2$$

Nous avons donc que :

$$\nabla_{\vec{\beta}} \ln(\hat{\beta}_{\text{MV}}, \hat{\sigma}_{\text{MV}}^2) = 0 \implies \hat{\beta}_{\text{MV}} = \operatorname{argmin}_{\phi \in \mathbb{R}^p} \|Y - Z\phi\|^2 \quad (4)$$

Or, cela est le même résultat que les moindres carrés :

$$\boxed{Z^\# Y = \hat{\beta}_{\text{MV}}}$$

Nous avons aussi que :

$$\partial_{\sigma^2} \ln(\hat{\beta}_{\text{MV}}, \hat{\sigma}_{\text{MV}}^2) = 0 \implies -\frac{n}{\hat{\sigma}_{\text{MV}}^2} + \frac{1}{(\hat{\sigma}_{\text{MV}}^2)^2} \|Y - Z\hat{\beta}_{\text{MV}}\|^2 = 0$$

Ce qui implique que :

$$\boxed{\hat{\sigma}_{\text{MV}}^2 = \frac{1}{n} \|Y - Z\hat{\beta}\|^2}$$

Cela est un point de maximum car :

$$\partial_{\sigma^2}^2 \ln(\hat{\beta}_{\text{MV}}, \hat{\sigma}_{\text{MV}}^2) = \frac{n}{(\hat{\sigma}_{\text{MV}}^2)^2} - \frac{2}{(\hat{\sigma}_{\text{MV}}^2)^3} \|Y - Z\hat{\beta}\|^2 = -\frac{1}{(\hat{\sigma}_{\text{MV}}^2)^3} \|Y - Z\hat{\beta}\|^2 < 0$$

### Exercice 12

Sous  $\mathbb{P}_\theta$ , comme  $Y \sim \mathcal{N}(Z\vec{\beta}, \sigma^2 \mathbf{I}_n)$  vecteur gaussien, nous avons que :

$$\hat{\beta} = Z^\# Y \sim \mathcal{N}(Z^\# Z \vec{\beta}, \sigma^2 Z^\# Z^t)$$

Or, mais comme déjà démontré,  $Z^\# Z = \mathbf{I}_n$  et  $Z^\# Z^t = (Z^t Z)^{-1}$  :

$$\hat{\beta} = Z^\# Y \sim \mathcal{N}(\vec{\beta}, \sigma^2 (Z^t Z)^{-1})$$



## Devoir Maison 1

---

### Exercice 13

Par le théorème de Cochran :

$$\frac{\|(I_n - H)Y\|^2}{\sigma^2} \sim \chi^2(\dim(I_n - H))$$

Or, comme  $H$  est un projecteur dans un espace de dimension  $p$ ,  $\dim(I_n - H) = n - p$  :

$$n \frac{\hat{\sigma}_{\text{MV}}^2}{\sigma^2} \sim \chi^2(n - p)$$

Nous avons donc que :

$$\hat{\sigma}_{\text{MV}}^2 \sim \frac{\sigma^2}{n} \xi \quad \text{où} \quad \xi \sim \chi^2(n - p)$$

### Exercice 14

D'après le théorème de Cochran,  $HY$  et  $(I_n - H)Y$  sont indépendants. Comme  $\rho \mapsto Z\rho$  et  $\rho \mapsto \frac{\|\rho\|^2}{n}$  sont mesurables sur  $\Theta$ , alors  $\hat{\beta} = Z^\# Y$  et  $\hat{\sigma} = \frac{1}{n} \|(I_n - H)Y\|^2$  sont indépendants sur  $\mathbb{P}_\theta$ .

## 1.4 Tests statistiques, cas régression linéaire gaussienne

### Exercice 15

D'après les résultats précédentes:

$$\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2(Z^t Z)^{-1})$$

Alors,  $\forall x \in \mathbb{R}^p$ :

$$x^t \beta \sim \mathcal{N}(x^t \beta, \sigma^2 x^t (Z^t Z)^{-1} x)$$

Ce qu'implique:

$$\eta = \frac{x^t (\hat{\beta} - \beta)}{\sigma \sqrt{x^t (Z^t Z)^{-1} x}} \sim \mathcal{N}(0, 1)$$

Aussi:

$$\lambda = (n - p) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n - p)$$

## Devoir Maison 1

---

Par définition de la Loi T de Student:

$$\frac{x^t(\hat{\beta} - \beta)}{\hat{\sigma} \sqrt{x^t(Z^t Z)^{-1}x}} = \frac{\eta}{\sqrt{\lambda/(n-p)}} \sim T(n-p)$$

### Exercice 16

Notons  $t_\alpha^{(n-p)}$  le  $\alpha$ -quantil de la loi T de Student a  $n-p$  degrees de liberté. Alors, on écrit:

$$\mathbb{P}_\theta \left( t_{\alpha/2}^{(n-p)} \leq \frac{x^t(\hat{\beta} - \beta)}{\hat{\sigma} \sqrt{x^t(Z^t Z)^{-1}x}} \leq t_{1-\alpha/2}^{(n-p)} \right) = 1 - \alpha$$

Alors:

$$\mathbb{P}_\theta \left( x^t \hat{\beta} - t_{1-\alpha/2}^{(n-p)} \Delta \leq x^t \beta \leq x^t \hat{\beta} - t_{\alpha/2}^{(n-p)} \Delta \right) = 1 - \alpha$$

Avec  $\Delta = \hat{\sigma} \sqrt{x^t(Z^t Z)^{-1}x}$ . D'où l'intervalle de confiance à niveau  $\alpha$ :

$$\boxed{\mathcal{I}_{1-\alpha} = \left[ x^t \hat{\beta} - t_{1-\alpha/2}^{(n-p)} \Delta, x^t \hat{\beta} - t_{\alpha/2}^{(n-p)} \Delta \right]}$$

Ci-dessous nous utiliserons toujours :

$$\Delta := \hat{\sigma} \sqrt{x^t(Z^t Z)^{-1}x}$$

### Exercice 17

Dans le cadre des hypothèses  $H_0$  et  $H_1$  de l'énoncé On propose le test suivante:

$$\phi_\alpha: z \in \mathbb{R}^p \mapsto \mathbf{1}_{\{|z^t x| > c_\alpha\}}$$

Et on calcule son niveau:

$$\begin{aligned} \bar{\alpha}(\phi_\alpha) &= \mathbb{P}_{H_0}(\phi_\alpha = 1) = \mathbb{P}_{H_0}(|\hat{\beta}^t x| > c_\alpha) \\ &= \mathbb{P}_{H_0} \left( \left| \frac{\hat{\beta}^t x}{\Delta} \right| > \frac{c_\alpha}{\Delta} \right) = F^{T(n-p)}(c_\alpha/\Delta) - F^{T(n-p)}(-c_\alpha/\Delta) \end{aligned}$$

Où  $F^{T(n-p)}$  est la fonction de répartition d'une loi T de Student de  $n-p$  degrés de liberté. D'après la parité de la loi:

$$\bar{\alpha}(\phi_\alpha) = 2(1 - F^{T(n-p)}(c_\alpha/\Delta))$$

## Devoir Maison 1

---

En fixant le niveau du test à  $\alpha$ :

$$\bar{\alpha}(\phi_\alpha) = \alpha = 2(1 - F^{T(n-p)}(c_\alpha/\Delta))$$

Alors:

$$F^{T(n-p)}(c_\alpha/\Delta) = 1 - \alpha/2$$

$$c_\alpha = \Delta t_{1-\alpha/2}^{n-p} = -\Delta t_{\alpha/2}^{n-p}$$

Alors, le test s'écrit:

$$\phi_\alpha: z \mapsto \mathbf{1}_{\{|z^t x| > \Delta t_{1-\alpha/2}^{n-p}\}}$$

### Exercice 18

Par définition de la p-valeur:

$$\hat{\alpha}(Z) = \operatorname{arginf}_{\alpha \in [0,1]} \phi_\alpha(Z) = 1$$

Ce que arrive quand  $|\hat{\beta}^t x| = c_\alpha$ . Alors:

$$\hat{\alpha} = 2 \left( 1 - F^{T(n-p)} \left( \frac{|\hat{\beta}^t x|}{\Delta} \right) \right)$$

### Exercice 19

On sait que

$$\hat{\beta} - \beta \sim \mathcal{N}(0, \sigma^2(Z^t Z)^{-1})$$

Un vecteur gaussien. Alors, comme  $\operatorname{rang}(A) = q$ , on a que:

$$A(\hat{\beta} - \beta) \sim \mathcal{N}(0, \sigma^2 A^t (Z^t Z)^{-1} A)$$

On rappelle le résultat suivante: Pour une matrice de covariance  $\Sigma \in \mathcal{M}_{d \times d}$ :

$$X \sim \mathcal{N}(\vec{0}, \Sigma) \implies X^t \Sigma^{-1} X \sim \chi^2(d)$$

Alors:

$$\frac{1}{\sigma^2} \left( A(\hat{\beta} - \beta) \right)^t \left[ A(Z^t Z)^{-1} A^t \right]^{-1} \left( A(\hat{\beta} - \beta) \right) \sim \chi^2(q)$$

On rappelle que  $(n-p)\hat{\sigma}^2/\sigma^2 \sim \chi^2(n-p)$ . Or, comme  $\hat{\beta}$  et  $\hat{\sigma}^2$  sont indépendantes par Cochran, leurs transformations le sont aussi. Alors, par la définition de la loi de Fisher  $F$ :

## Devoir Maison 1

---

$$\frac{\frac{1}{\sigma^2} \left( A(\hat{\beta} - \beta) \right)^t [A(Z^t Z)^{-1} A^t]^{-1} \left( A(\hat{\beta} - \beta) \right)}{(n-p)\hat{\sigma}^2/\sigma^2} \times \frac{n-p}{q} \sim F(q, n-p)$$

Donc:

$$\frac{1}{q\hat{\sigma}^2} \left( A(\hat{\beta} - \beta) \right)^t [A(Z^t Z)^{-1} A^t]^{-1} \left( A(\hat{\beta} - \beta) \right) \sim F(q, n-p)$$

### Exercice 20

Ici on pose:

$$A_{2 \times p} = \begin{pmatrix} I_2 \\ 0 \end{pmatrix}$$

Comme  $Z^t Z$  est une matrice réelle symétrique, alors elle est diagonalisable sur une base orthonormale. Donc il existe une matrice orthonormale  $P$  et une matrice diagonale  $D$  tels que:

$$Z^t Z = P^t D P$$

D'après l'exercice 8,  $(Z^t Z)^{-1}$  est une matrice de covariance. Alors elle est définie positive, ce qu'implique que les valeurs propres de  $Z^t Z$  sont positives. Naturellement  $D \geq 0$ .

Alors:

$$\Lambda = (A(Z^t Z)^{-1} A^t)^{-1} = (A P^t) D (A P^t)^t$$

Une matrice  $2 \times 2$  diagonalisable. On note  $\{v_1, v_2\}$  la famille de vecteurs propres orthonormale et  $\{\lambda_1, \lambda_2\}$  les valeurs propres associés.

On note que  $\forall l \in \mathbb{R}_*^+$ :

$$\left( A(\hat{\beta} - \beta) \right)^t \Lambda \left( A(\hat{\beta} - \beta) \right) = l$$

$$\left( (\beta_1, \beta_2) - (\hat{\beta}_1, \hat{\beta}_2) \right)^t \Lambda \left( (\beta_1, \beta_2) - (\hat{\beta}_1, \hat{\beta}_2) \right) = l$$

Décrit une ellipse sur le plan  $(\beta_1, \beta_2)$ , centrée en  $(\hat{\beta}_1, \hat{\beta}_2)$  de axes orthogonaux  $v_1$  et  $v_2$

On écrit  $f_{\alpha}^{q, n-p}$  le  $\alpha$ -quantil d'une loi de Fisher de paramètres  $q, n-p$ .

Donc la région de confiance de  $(\beta_1, \beta_2)$  est une couronne elliptique:

$$\boxed{2\hat{\sigma}^2 f_{\alpha/2}^{2, n-p} \leq \left( (\beta_1, \beta_2) - (\hat{\beta}_1, \hat{\beta}_2) \right)^t \Lambda \left( (\beta_1, \beta_2) - (\hat{\beta}_1, \hat{\beta}_2) \right) \leq 2\hat{\sigma}^2 f_{1-\alpha/2}^{2, n-p}}$$

```
In [ ]: import pandas as pd
import numpy as np

import matplotlib.pyplot as plt
from matplotlib.patches import Ellipse

from scipy.stats import chi2
from scipy.stats import t as student
from scipy.stats import f as fisher
```

```
In [ ]: df = pd.read_csv("ozone_complet.txt", sep=';').dropna()
df
```

```
Out[ ]:
```

	maxO3	T6	T9	T12	T15	T18	Ne6	Ne9	Ne12	Ne15	...	Vdir9	Vvit9	Vdir12
<b>19950401</b>	47.6	10.1	11.6	13.3	13.6	12.2	8.0	8.0	8.0	8.0	...	290.0	4.0	300.0
<b>19950402</b>	56.2	9.5	9.4	13.8	17.4	16.3	8.0	8.0	7.0	0.0	...	160.0	2.0	180.0
<b>19950403</b>	61.8	3.6	8.0	16.8	21.5	20.2	4.0	5.0	2.0	2.0	...	20.0	2.0	340.0
<b>19950404</b>	50.8	9.5	10.5	11.4	12.2	11.4	8.0	7.0	7.0	7.0	...	10.0	4.0	350.0
<b>19950405</b>	59.8	9.8	10.8	13.8	14.3	13.3	8.0	7.0	8.0	8.0	...	340.0	2.0	280.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
<b>20020926</b>	76.0	7.0	13.7	17.0	17.9	15.3	4.0	7.0	8.0	7.0	...	290.0	4.0	330.0
<b>20020927</b>	79.0	10.2	11.5	18.3	20.0	17.1	9.0	9.0	2.0	6.0	...	70.0	2.0	120.0
<b>20020928</b>	91.0	6.2	14.1	19.8	21.1	18.1	0.0	0.0	1.0	2.0	...	120.0	3.0	120.0
<b>20020929</b>	89.0	8.1	14.8	20.4	22.0	18.4	4.0	5.0	5.0	4.0	...	120.0	4.0	130.0
<b>20020930</b>	99.0	9.4	13.8	21.7	24.7	19.8	6.0	6.0	6.0	3.0	...	140.0	2.0	140.0

1366 rows × 23 columns

1)

```
In [ ]: Y = np.matrix(df.maxO3v).transpose()
Z = np.matrix([df.T12, df.Vx, df.Ne12, np.ones((Y.size,))]).transpose().astype(float)

n = Y.size
p = Z.shape[1]

Z_sharp = (Z.transpose() @ Z) ** -1 * Z.transpose()
beta_hat = Z_sharp * Y

beta_hat
```

```
Out[ ]: matrix([[ 1.44661518],
[ 0.88444208],
[-1.33507028],
[64.66754543]])
```

```
In [ ]: epsilon = Y - Z * beta_hat
sigma_hat = np.linalg.norm(epsilon) / np.sqrt(n - p)
```

```
sigma_hat
```

```
Out[ ]: 20.97181272920036
```

## 2)

```
In [ ]: def one_hot(i, n):
    a = np.zeros((n, 1))
    a[i] = 1
    return a.transpose()

def beta_interval(x_t, beta_hat, alpha):
    delta = sigma_hat * np.sqrt(x_t * ((Z.transpose() @ Z) ** -1) * x_t.transpose())
    quant = student.ppf(1 - alpha / 2, n - p)

    return x_t * beta_hat + delta * np.array([-quant, quant])

def sigma_2_interval(sigma_hat, alpha):
    quant = np.array([1 / chi2.ppf(1 - alpha / 2, n - p), 1 / chi2.ppf(alpha / 2, n - p)])
    return sigma_hat ** 2 * (n - p) * quant
```

```
In [ ]: alpha = .05
beta_intervals = [beta_interval(one_hot(i, p), beta_hat, alpha) for i in range(p)]
beta_intervals
```

```
Out[ ]: [matrix([[1.18142349, 1.71180687]]),
matrix([[0.52652976, 1.24235439]]),
matrix([[-1.93511358, -0.73502697]]),
matrix([[57.36033557, 71.97475529]])]
```

```
In [ ]: sigma_interval = np.sqrt(sigma_2_interval(sigma_hat, alpha))
sigma_interval
```

```
Out[ ]: array([20.21303734, 21.79021216])
```

## 3)

```
In [ ]: def conf_ellip(A, Z, beta_hat, sigma_hat, alpha, rem_zeros=False):
    q = A.shape[0]

    Z_proj = A @ np.linalg.inv(Z.transpose() @ Z) @ A.transpose()
    if rem_zeros:
        nzero_rows = np.flatnonzero(~np.all(Z_proj == 0, axis=0))
        nzero_cols = np.flatnonzero(~np.all(Z_proj == 0, axis=1))
        Z_proj = Z_proj[nzero_rows,:]
        Z_proj = Z_proj[:, nzero_cols]

    Lambda = np.linalg.inv(Z_proj) / (q * sigma_hat ** 2)
    l, v = np.linalg.eig(Lambda)

    f1 = fisher.ppf(alpha / 2, q, n - p)
    f2 = fisher.ppf(1 - alpha / 2, q, n - p)

    d1 = np.sqrt(f1 / l)
    d2 = np.sqrt(f2 / l)
```

```
gamma = np.degrees(np.arctan2(v[0, 1], v[0, 0]))
ell1 = (d1[0], d1[1], gamma)
ell2 = (d2[0], d2[1], gamma)

return (ell1, ell2)
```

In [ ]:

```
A = np.zeros((2, p))
A[0, 0] = 1
A[1, 1] = 1

ell1, ell2 = conf_ellip(A, Z, beta_hat, sigma_hat, alpha, rem_zeros=False)

small_obj = Ellipse(beta_hat[:2], *ell1)
large_obj = Ellipse(beta_hat[:2], *ell2)

ax = plt.gca()
ax.add_artist(small_obj)
ax.add_artist(large_obj)

small_obj.set_fill(False)
small_obj.set_edgecolor('cornflowerblue')
small_obj.set_linewidth(2)


large_obj.set_fill(False)
large_obj.set_edgecolor('cornflowerblue')
large_obj.set_linewidth(2)

ax.set_xlim(-.2 + beta_hat[0], .2 + beta_hat[0])
ax.set_ylim(-.4 + beta_hat[1], .4 + beta_hat[1])

ax.set_xlabel("Beta 1 [-]")
ax.set_ylabel("Beta 2 [-]")

ax.grid()

plt.show()
```



In [ ]:

```

q = 3
A = np.zeros((q, p))
A[0, 0] = 1
A[2, 2] = 1

ell1, ell2 = conf_ellip(A, Z, beta_hat, sigma_hat, alpha, rem_zeros=True)

small_obj = Ellipse(beta_hat[[0,2]], *ell1)
large_obj = Ellipse(beta_hat[[0,2]], *ell2)

ax = plt.gca()
ax.add_artist(small_obj)
ax.add_artist(large_obj)

small_obj.set_fill(False)
small_obj.set_edgecolor('cornflowerblue')
small_obj.set_linewidth(2)

large_obj.set_fill(False)
large_obj.set_edgecolor('cornflowerblue')
large_obj.set_linewidth(2)


ax.set_xlim(-.25 + beta_hat[0], .25 + beta_hat[0])
ax.set_ylim(-.55 + beta_hat[2], .55 + beta_hat[2])

ax.set_xlabel("Beta 1 [-]")
ax.set_ylabel("Beta 3 [-]")

ax.grid()
plt.show()

```





#### 4)

(i)

La question numéro (i) peut être formulé autrement comme le test d'hypothèse suivant :

$$H0 : \beta_2 = 0, \text{ contre } H1 : \beta_2 \neq 0$$

C'est à dire que nous testons si le paramètre qui multiplie  $Vx$  est égal à zéro, ce qui indiquerait une non-dépendance de  $O3$  par rapport à  $Vx$  (une dépendance non-linéaire resterait toujours possible).

(ii)

De même, nous pouvons considérer le test suivant:

$$H0 : \beta_3 = 0, \text{ contre } H1 : \beta_3 \neq 0$$

(iii)

Pour vérifier l'influence par  $Vx$  ou  $T12$  nous pouvons considérer le test suivant:

$$H0 : (\beta_1, \beta_3) = 0, \text{ contre } H1 : (\beta_1, \beta_3) \neq 0$$

Où l'hypothèse  $H0$  est l'inexistence d'une dépendance lineaire entre  $O3$  et  $(Vx, T12)$

#### 5)

La procédure pour les tests (i) et (ii) découle directement de la formule de l'item 17.

Pour le test (iii) nous pouvons utiliser la dualité entre les tests d'hypothèse et les intervalles de confiance. C'est-à-dire, nous vérifions si la région de confiance de  $(\beta_1, \beta_3)$ , à niveau  $\alpha$  égal à celui du test désiré, contient l'origine.

```
In [ ]: def test_beta(x, alpha, beta_hat, sigma_hat, Z):
        x_t = x.transpose()
        delta = sigma_hat * np.sqrt(x_t * ((Z.transpose() @ Z) ** -1) * x)
        quant = student.ppf(1 - alpha / 2, n - p)

        return np.abs(beta_hat.transpose() * x) > delta * quant
```

```
In [ ]: def p_valeur(x, beta_hat, sigma_hat, Z):
        x_t = x.transpose()
        delta = sigma_hat * np.sqrt(x_t * ((Z.transpose() @ Z) ** -1) * x)

        return 2 * (1 - student.cdf((np.abs(beta_hat.transpose() @ x))/(delta), n - p))
```

(i)

```
In [ ]: if test_beta(one_hot(1, p).transpose(), alpha, beta_hat, sigma_hat, Z):
        print("H0 rejetée.")
        print("p-valeur = " + str(p_valeur(one_hot(1, p).transpose(), beta_hat, sigma_hat, Z)))
    else:
        print("H0 acceptée.")
        print("p-valeur = " + str(p_valeur(one_hot(1, p).transpose(), beta_hat, sigma_hat, Z)))
```

H0 rejetée.  
p-valeur = 1.39301782864365e-06

(ii)

```
In [ ]: if test_beta(one_hot(2, p).transpose(), alpha, beta_hat, sigma_hat, Z):
        print("H0 rejetée.")
        print("p-valeur = " + str(p_valeur(one_hot(2, p).transpose(), beta_hat, sigma_hat, Z)))
    else:
        print("H0 acceptée.")
        print("p-valeur = " + str(p_valeur(one_hot(2, p).transpose(), beta_hat, sigma_hat, Z)))
```

H0 rejetée.  
p-valeur = 1.3690449021552809e-05

(iii)

Le deuxième graphique de la question pratique 3 nous montre que l'origine n'est pas comprise dans la région de confiance de  $(\beta_1, \beta_3)$ . Alors, nous rejetons  $H_0$ .

## 6)

En conclusion, les tests montrent que les facteurs  $Vx$ ,  $T_{12}$  et  $N_{12}$  influencent la valeur de  $O_3$ .

Bien sur, ces résultats sont plausibles sous l'hypothèse que  $O_3$  suit un modèle gaussien linéaire dans les variables explicatives. En considérant des autres types de modèles plus complexes on pourrait arriver à des autres résultats.